DESAFIO 3 | Painel completo dos experimentos

Receita vencedora: Muon | LR=0.003 | OneCycle

Dice de validação: 0.7510 ± 0.0017 (n=3 sementes)

Baseline AdamW: 0.7267 ± 0.0058 (n=3 sementes)

Ganho pareado (mesmas sementes): +0.0243 ± 0.0042 Dice

Experimentos registrados: 46; execuções com diverged=True: 0.

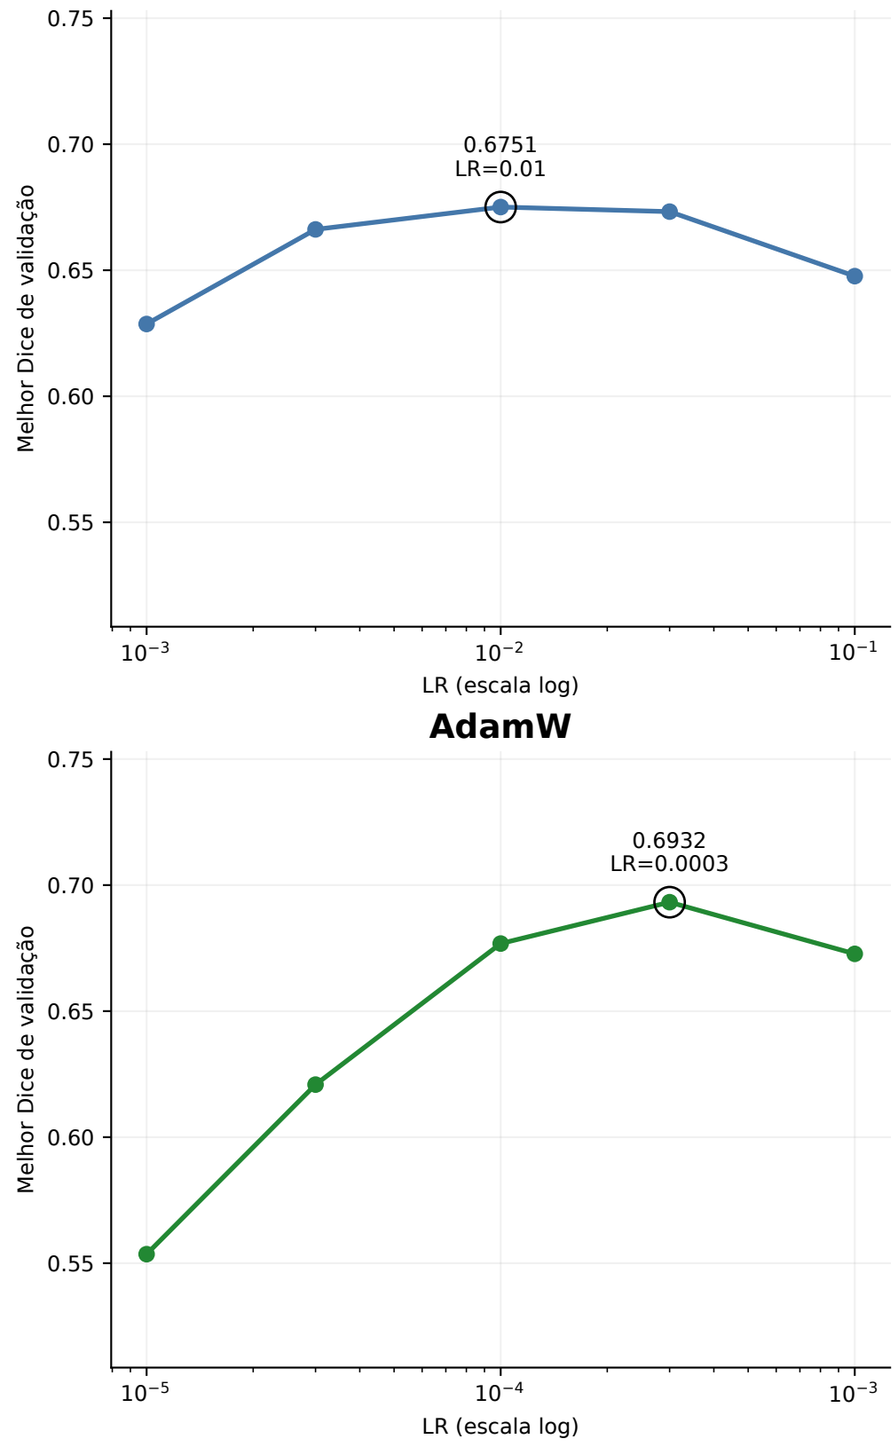
Varreduras e agendas: 5 épocas. Baseline e confirmação: 15 épocas.

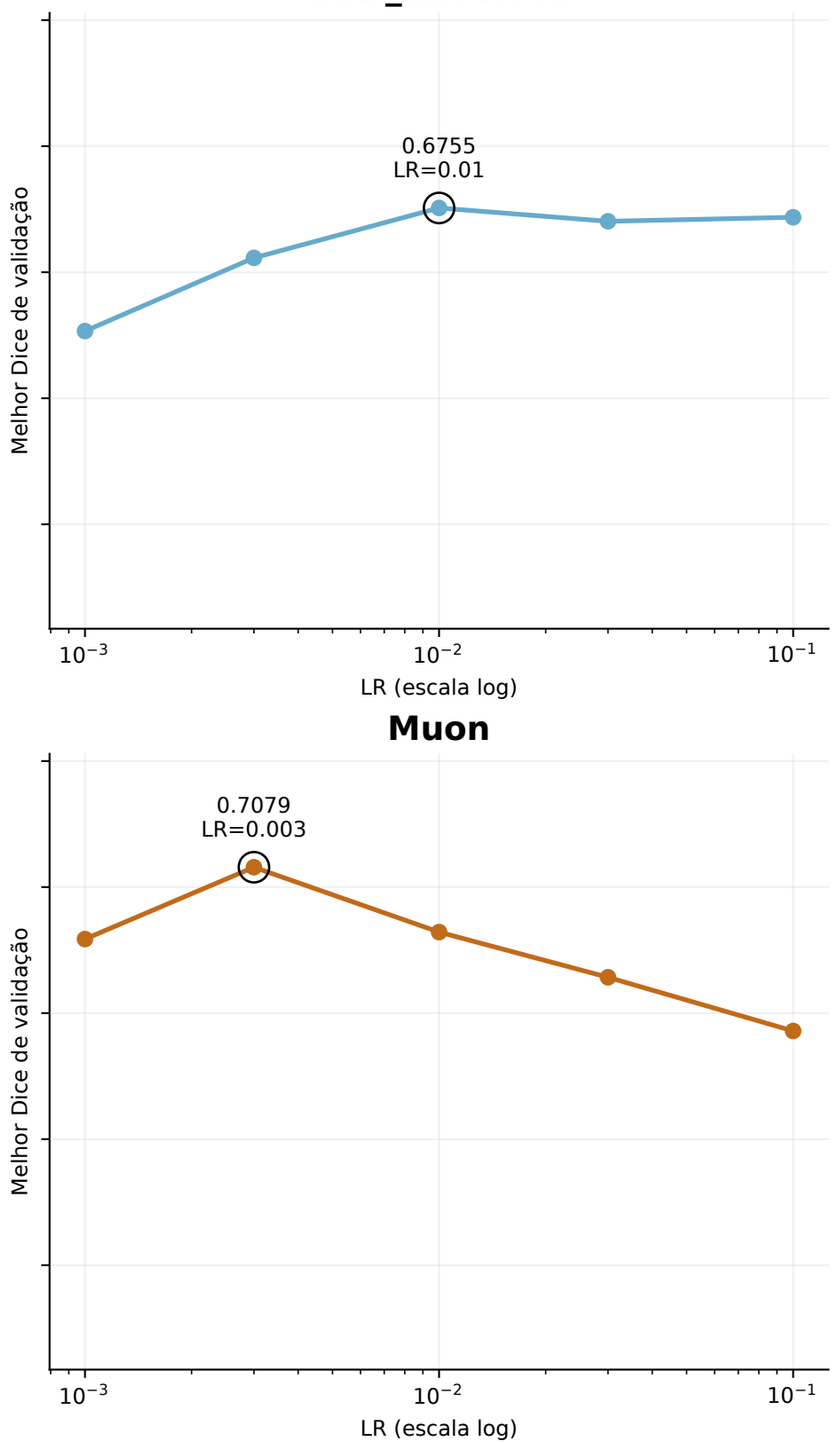
Seleção feita apenas pela validação; o teste final não é usado para escolher o vencedor.

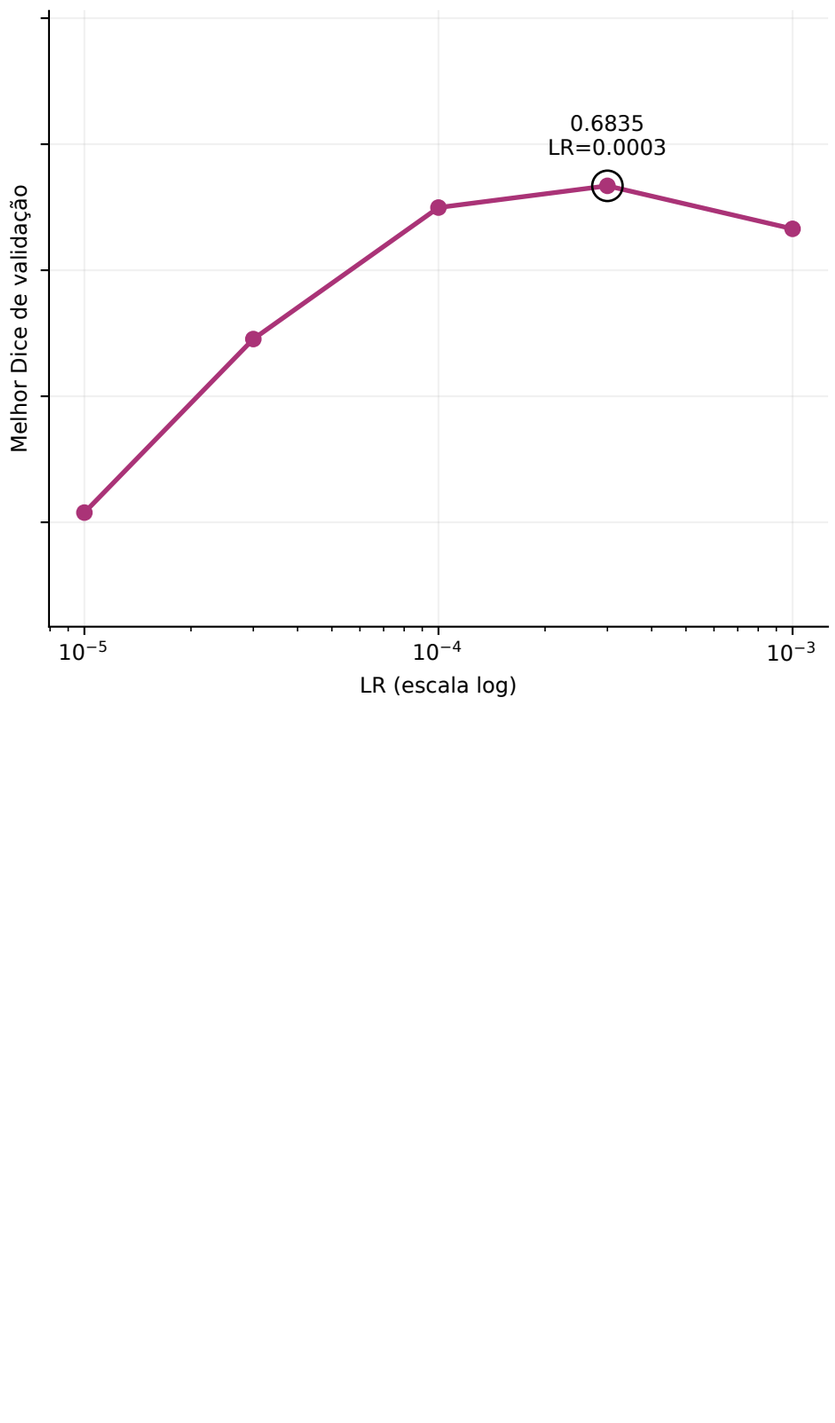
NOTAS DE INTERPRETAÇÃO

- Nenhuma execução consta como divergente no CSV; portanto, não inventamos um exemplo de divergência. Na página de diagnóstico há um controle de menor Dice, explicitamente rotulado como NÃO divergente.
- No Muon, o AdamW auxiliar foi executado com LR=0,0001, embora o melhor AdamW da varredura tenha LR=0,0003. Essa diferença deve ser relatada como limitação de protocolo.
- Os sinais brutos foram registrados periodicamente (não em todos os passos).
- As curvas por passo mostram a mesma semente (42) para não selecionar o melhor acaso.
- Norma do gradiente é medida antes de clipping; razão de atualização é medida por camada.

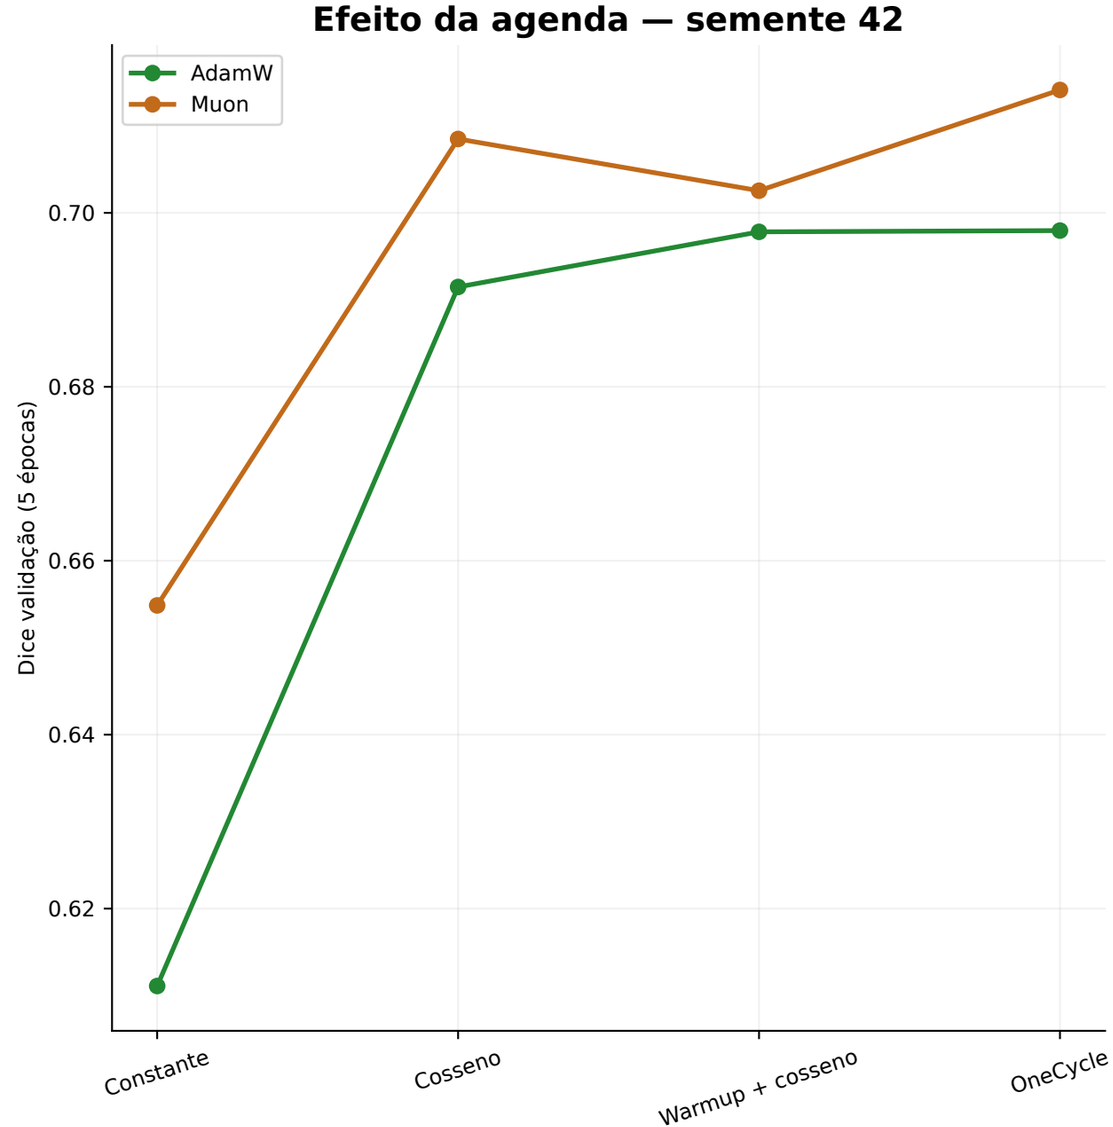
Métrica × learning rate por otimizador | varredura, 5 épocas e semente 42

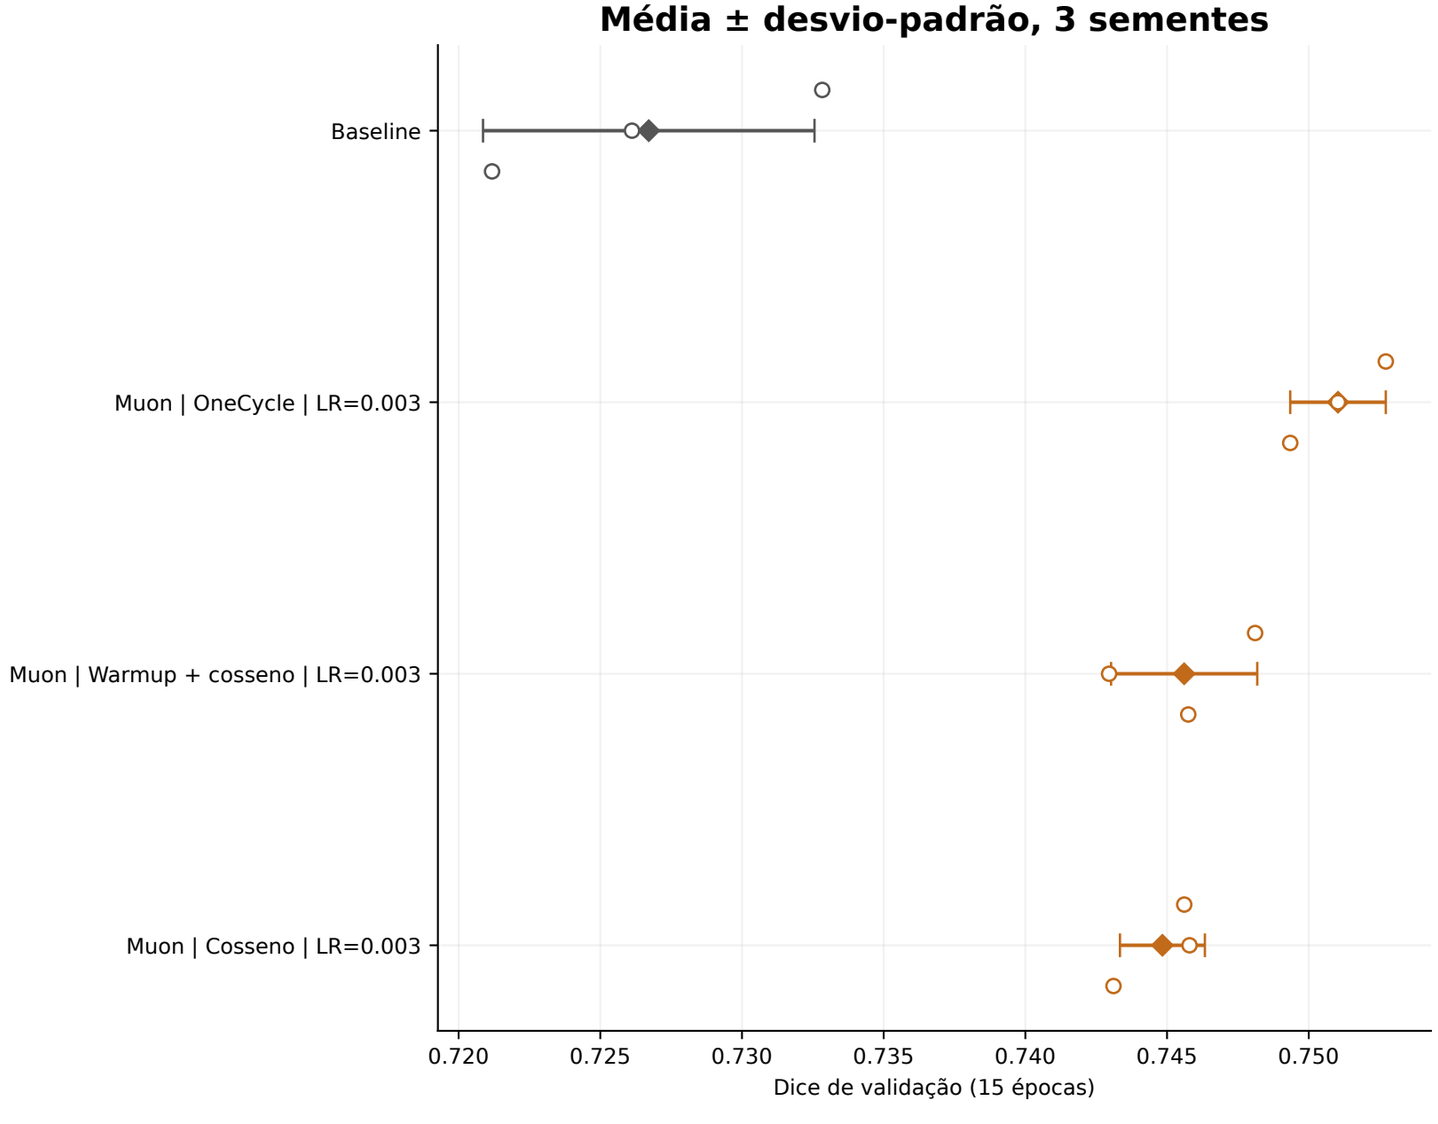






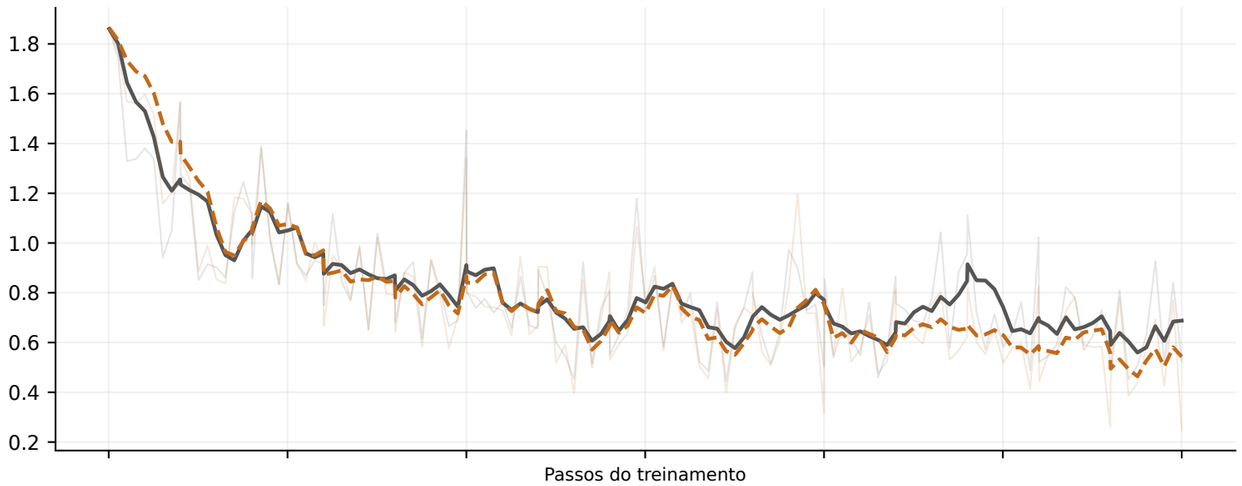
Agendas e confirmação: seleção sustentada por múltiplas sementes



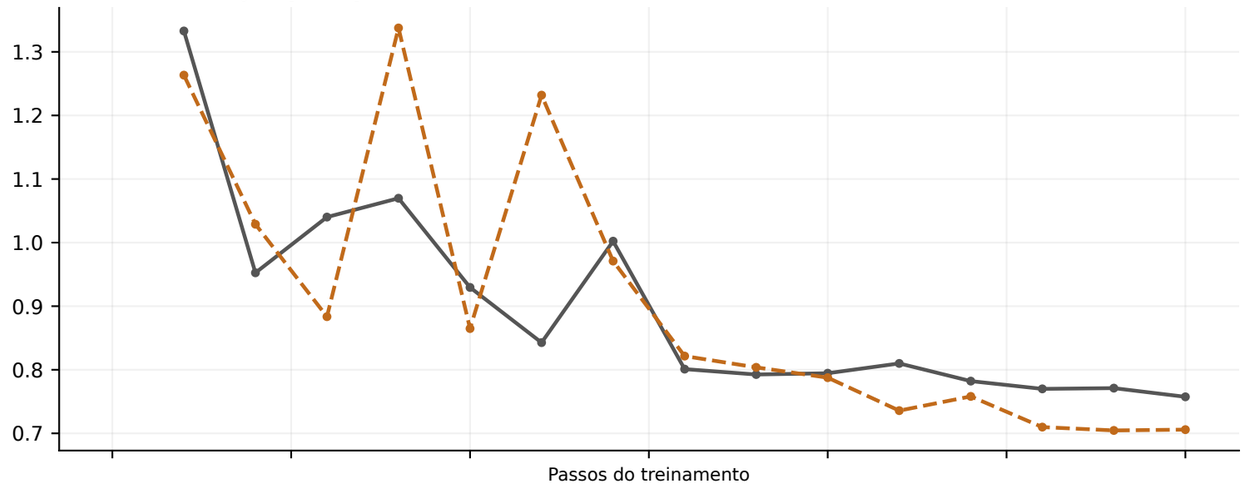


Baseline × melhor configuração | mesma semente, 15 épocas | sinais alinhados por passo

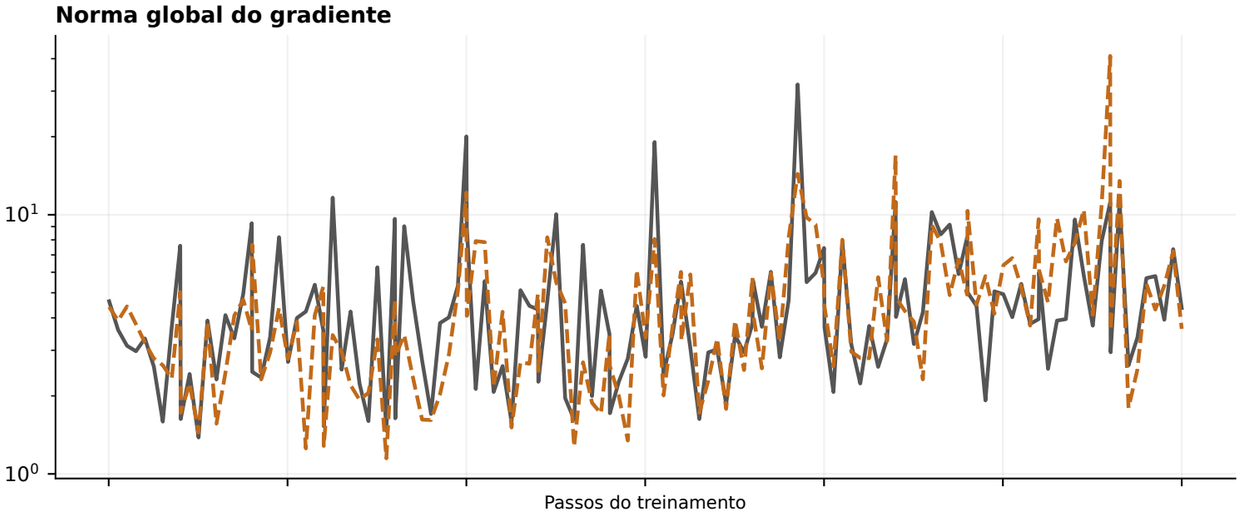
Loss de treino por lote



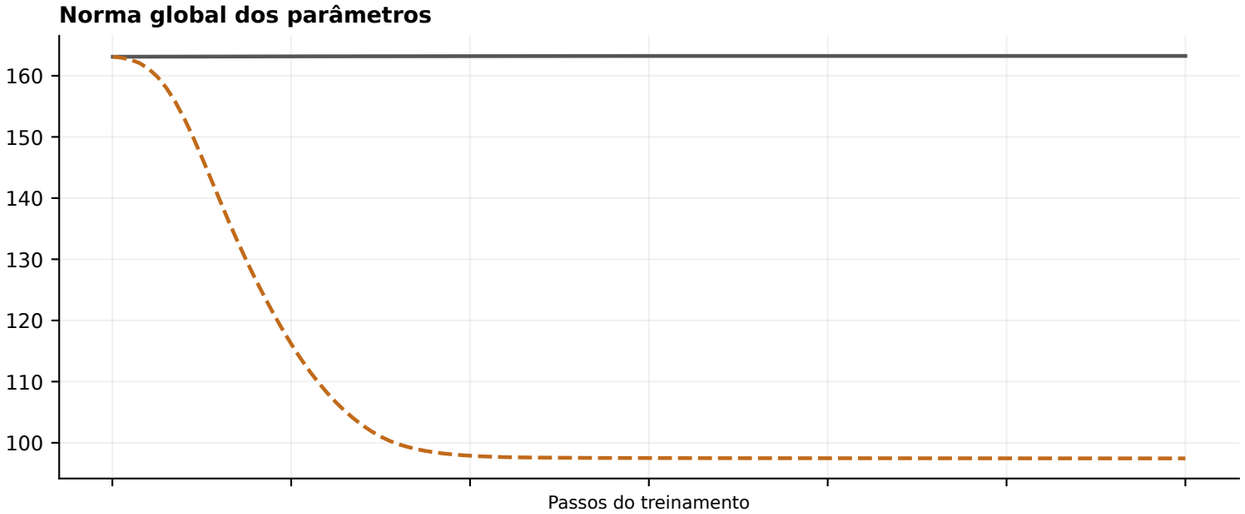
Loss de validação por época



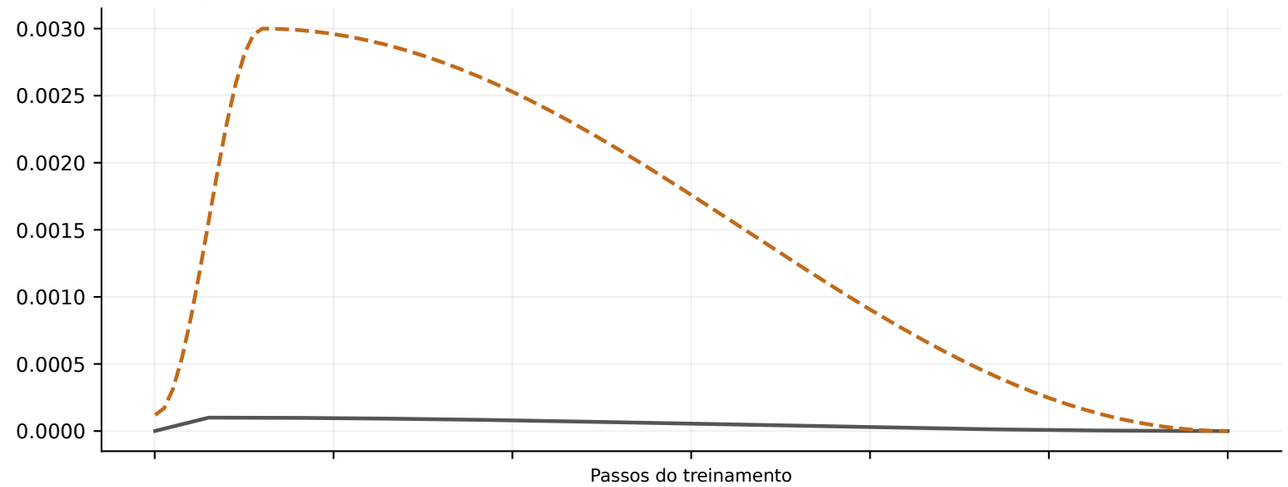
Norma global do gradiente



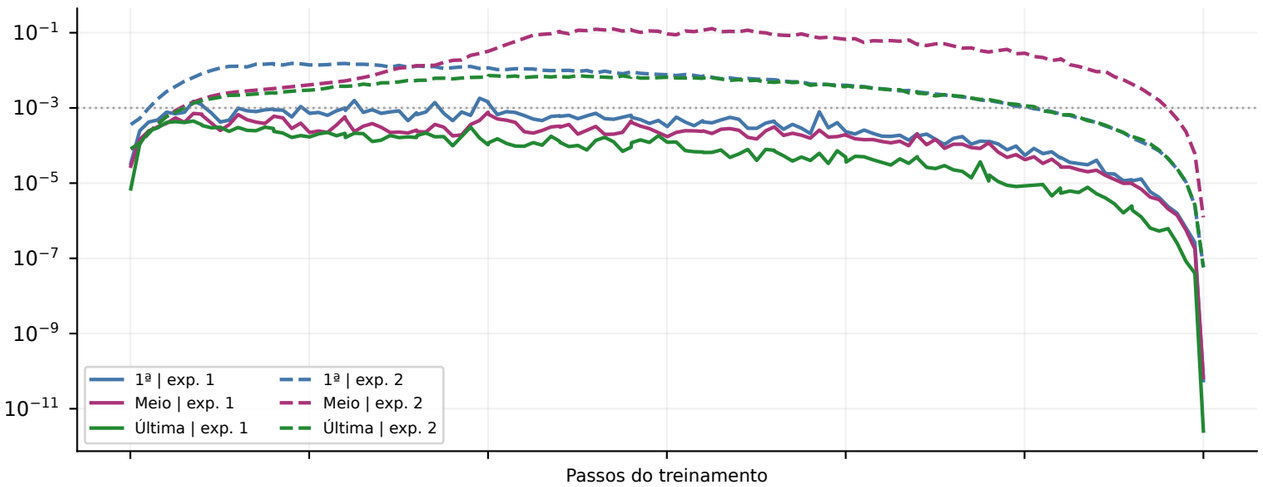
Norma global dos parâmetros



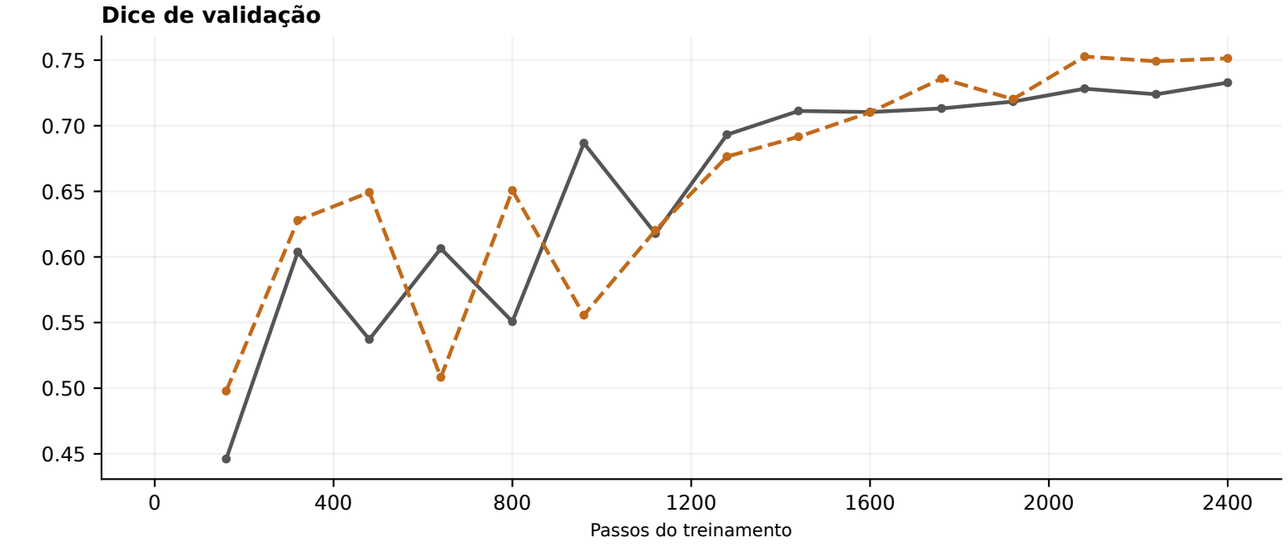
Learning rate principal



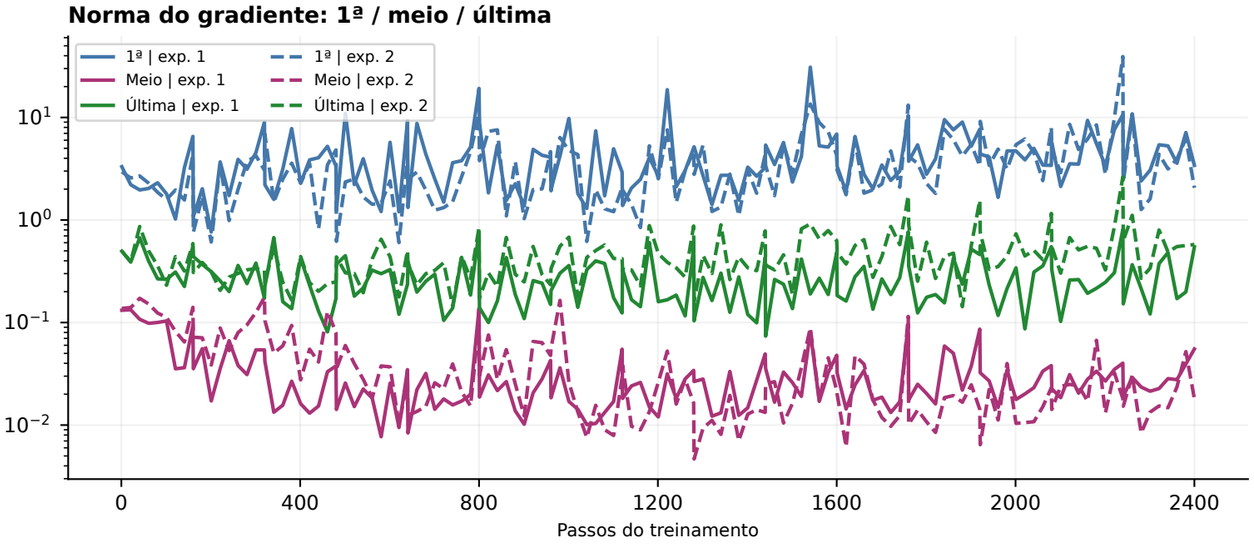
Razão de atualização: 1ª / meio / última



Dice de validação



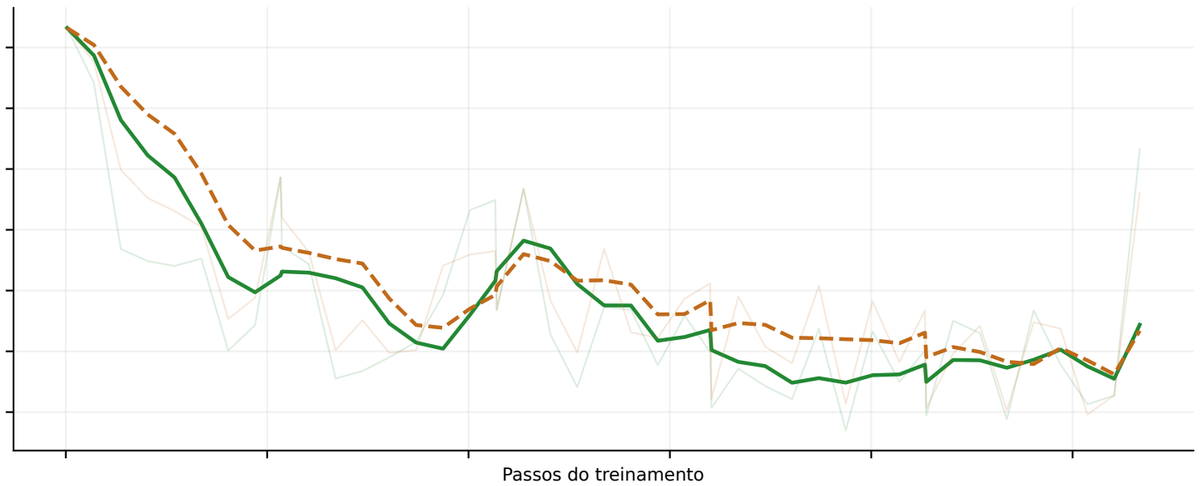
Norma do gradiente: 1ª / meio / última



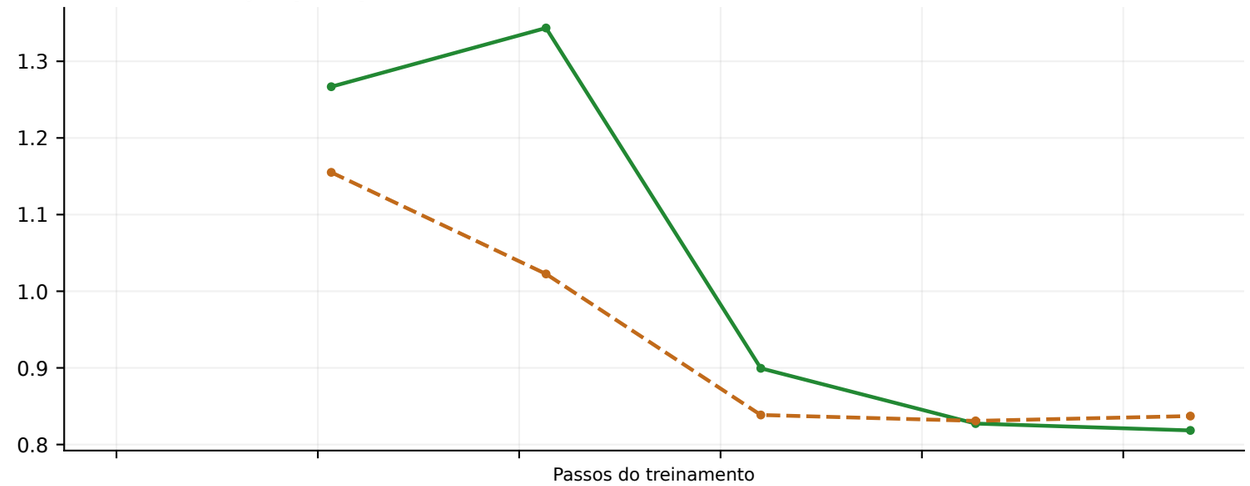
AdamW | LR=0.0001 | Warmup + cosseno | semente 42 | baseline
Muon | LR=0.003 | OneCycle | semente 42 | confirmation

Melhor Muon × melhor AdamW na comparação de agendas | 5 épocas | sinais alinhados

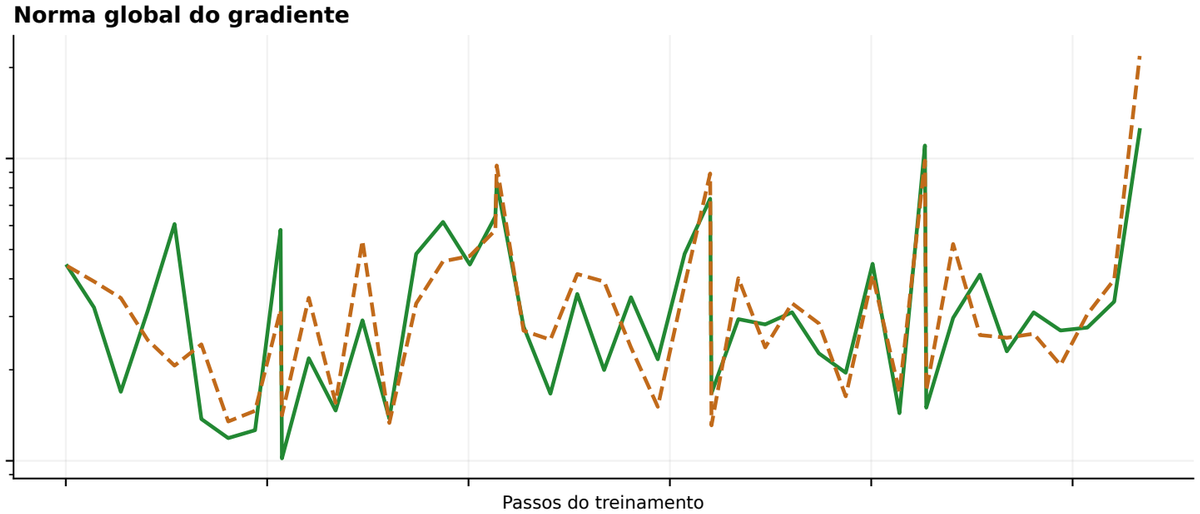
Loss de treino por lote



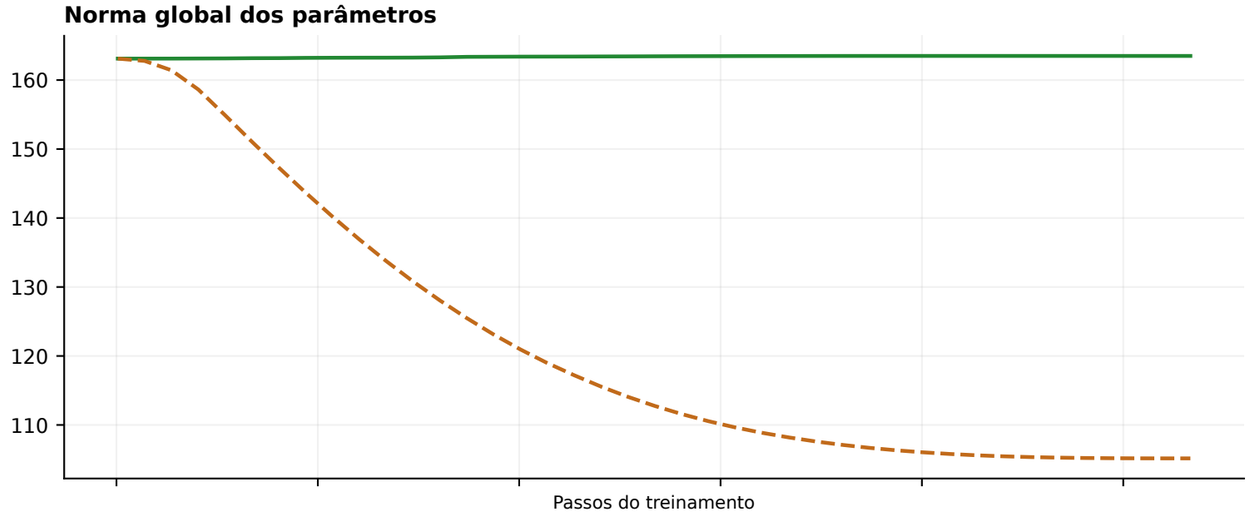
Loss de validação por época



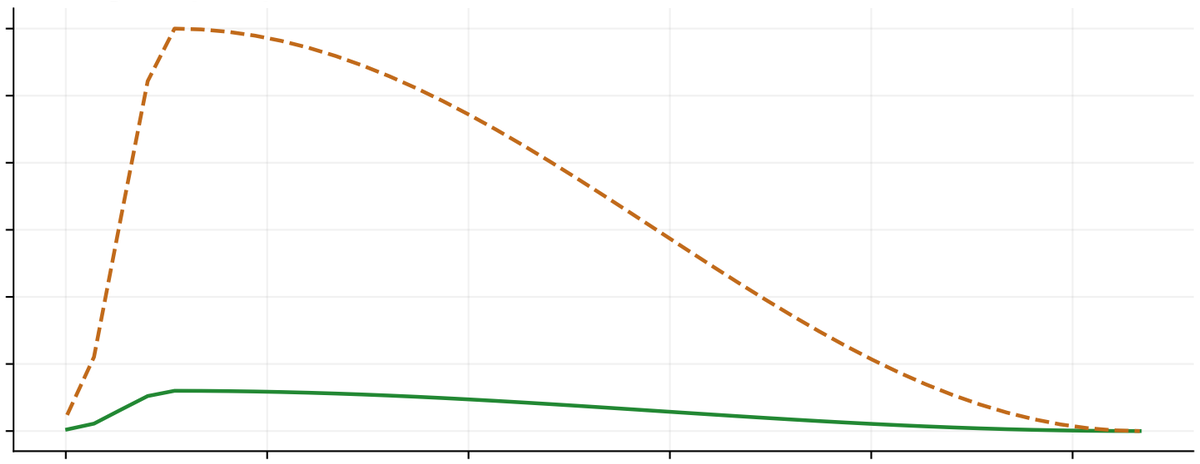
Norma global do gradiente



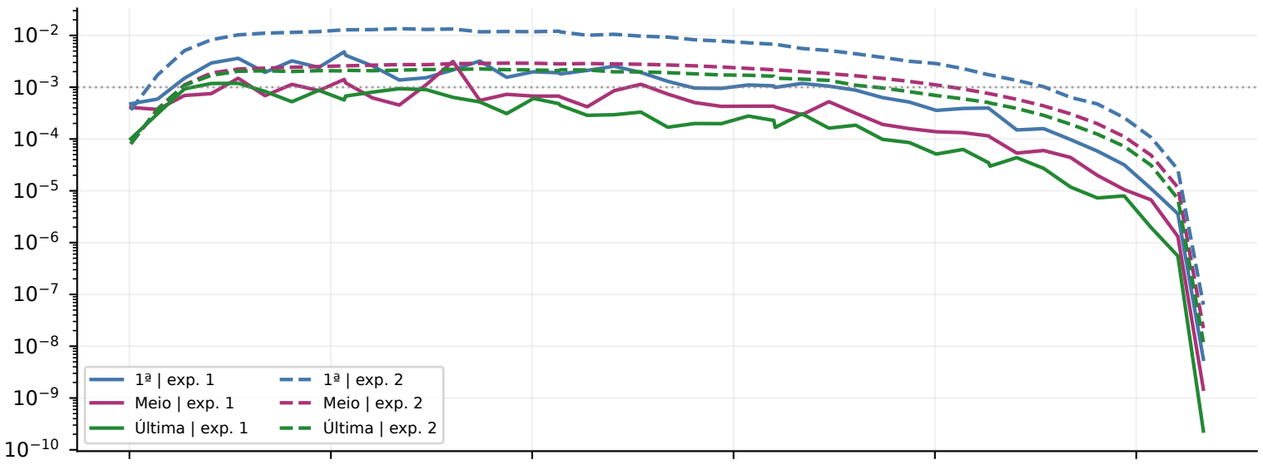
Norma global dos parâmetros



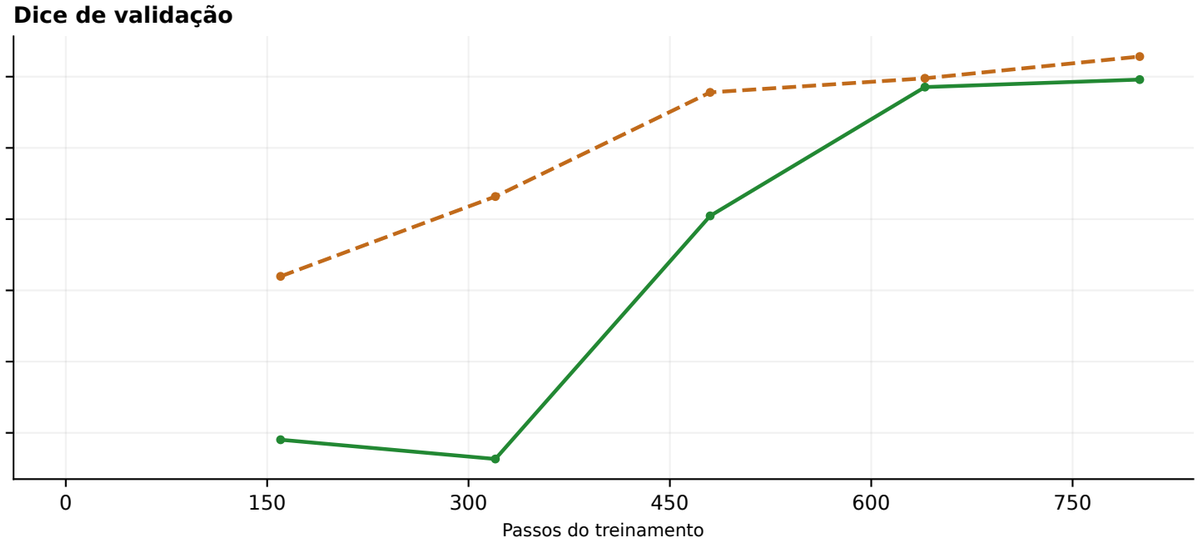
Learning rate principal



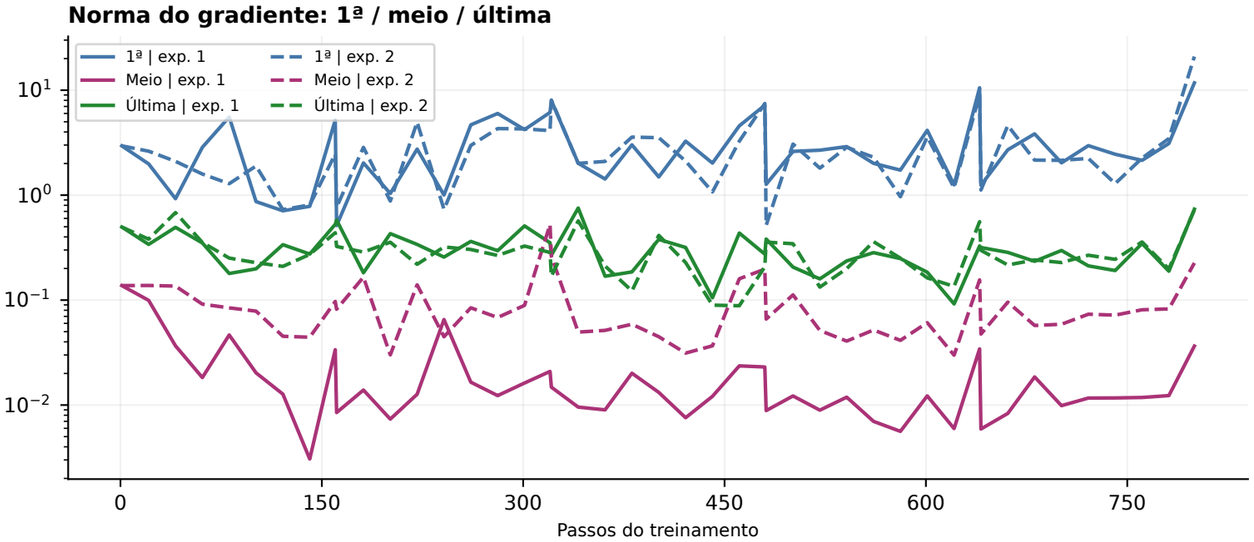
Razão de atualização: 1ª / meio / última



Dice de validação



Norma do gradiente: 1ª / meio / última

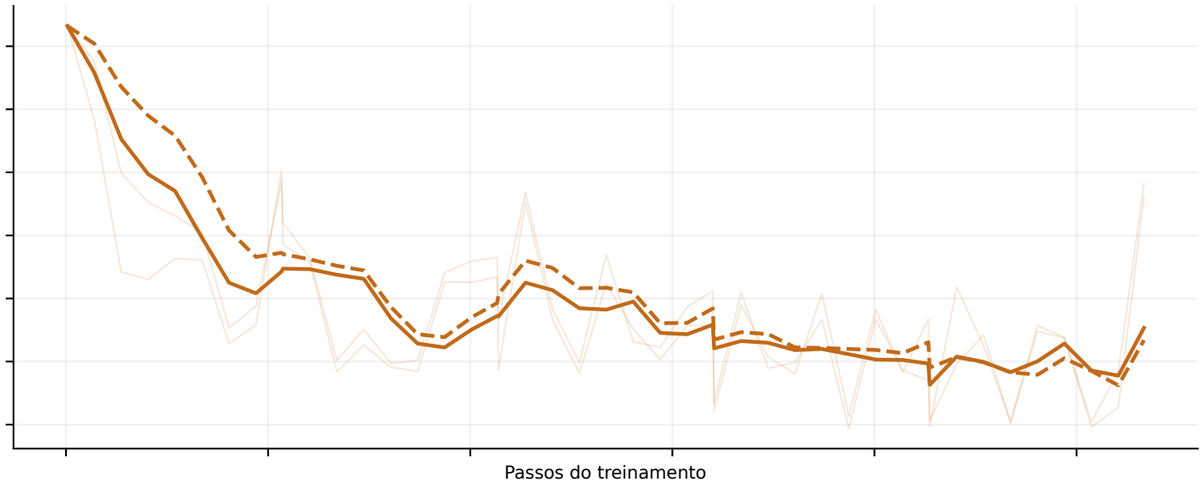


AdamW | LR=0.0003 | OneCycle | semente 42 | schedule_sweep

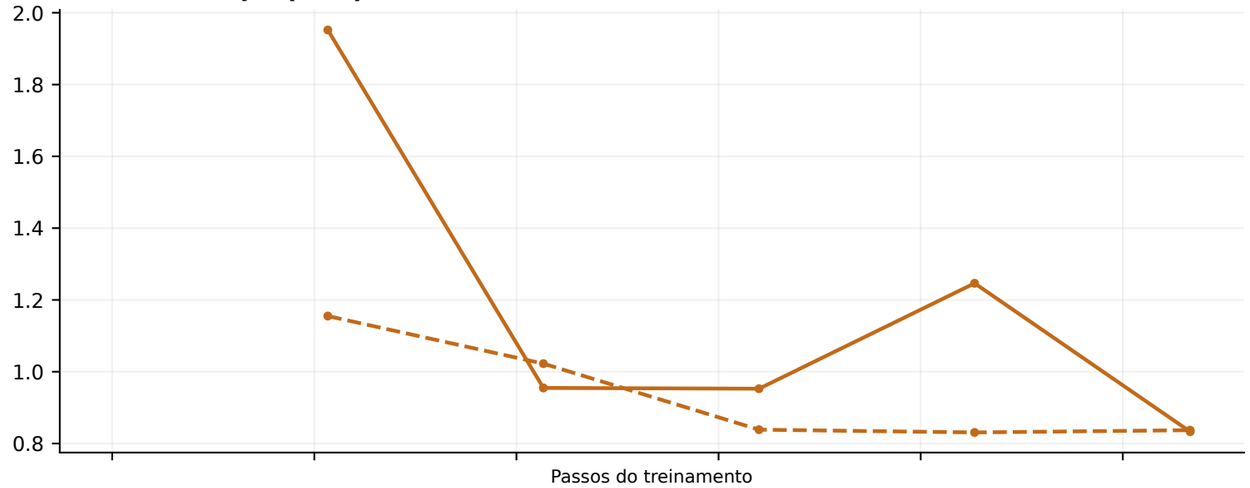
Muon | LR=0.003 | OneCycle | semente 42 | schedule_sweep

Diagnóstico da agenda: Muon constante × melhor agenda | 5 épocas

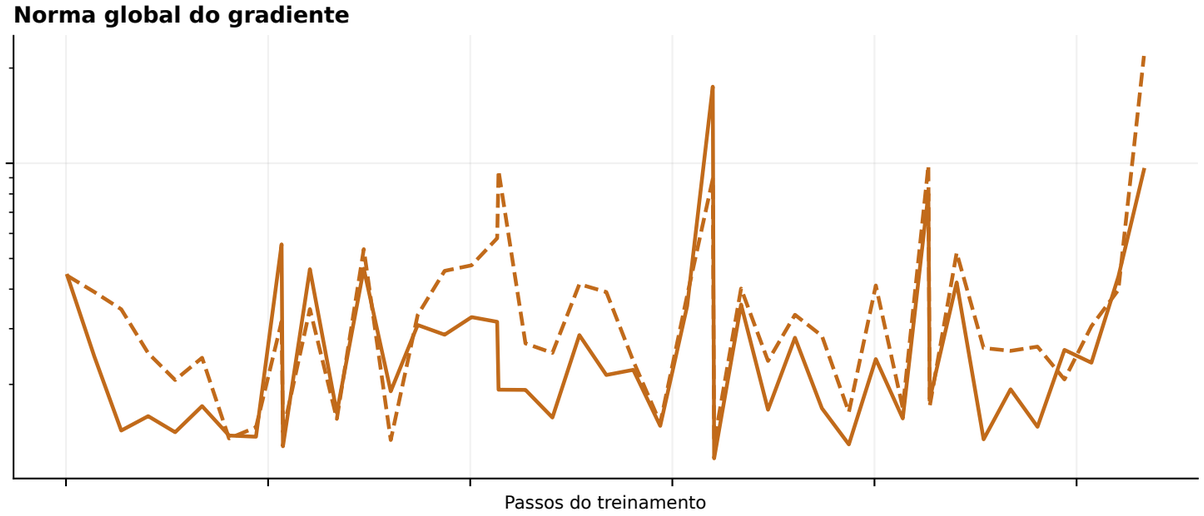
Loss de treino por lote



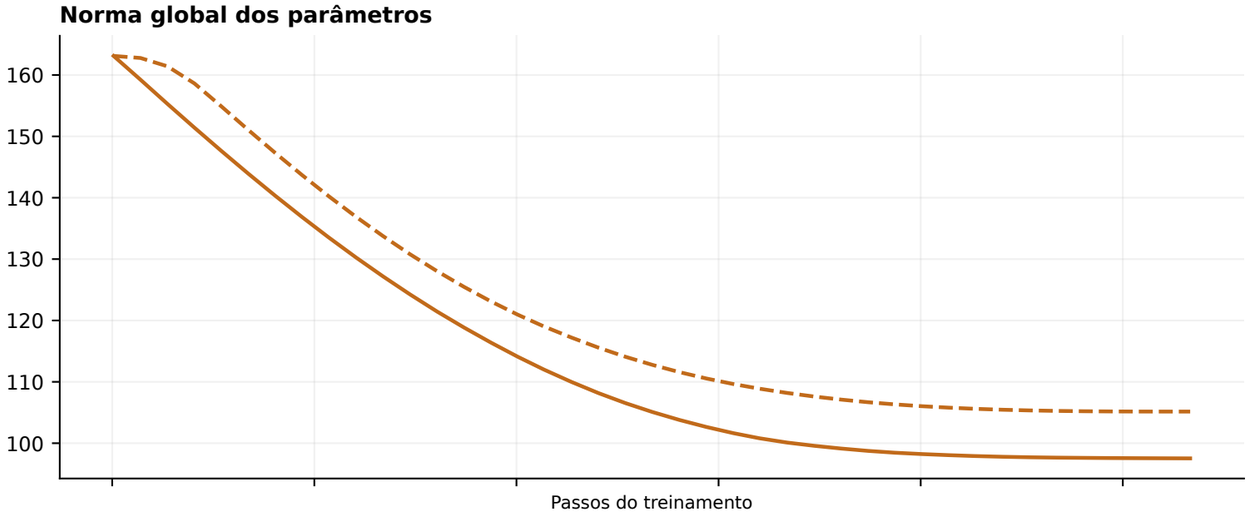
Loss de validação por época



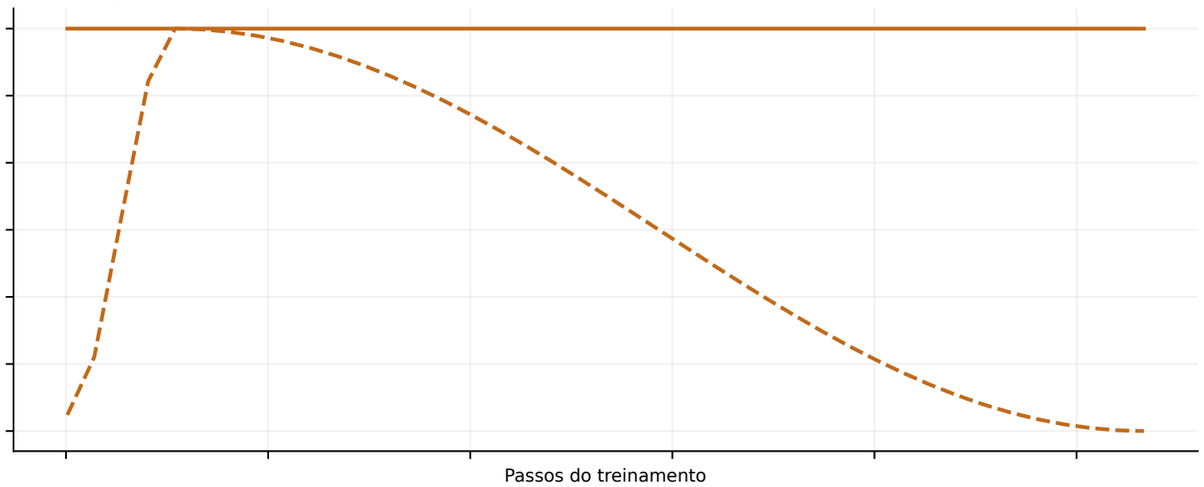
Norma global do gradiente



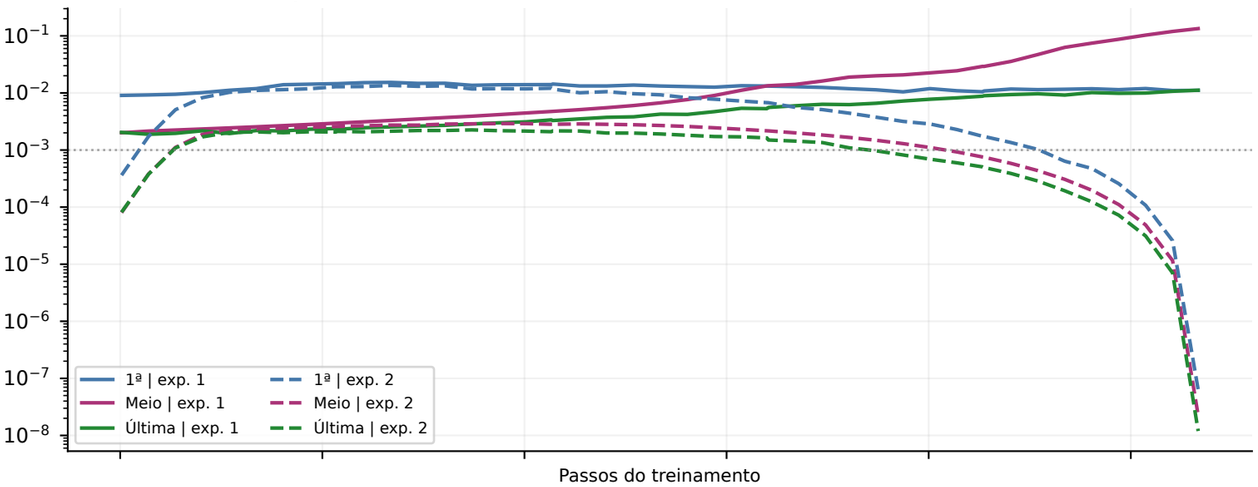
Norma global dos parâmetros



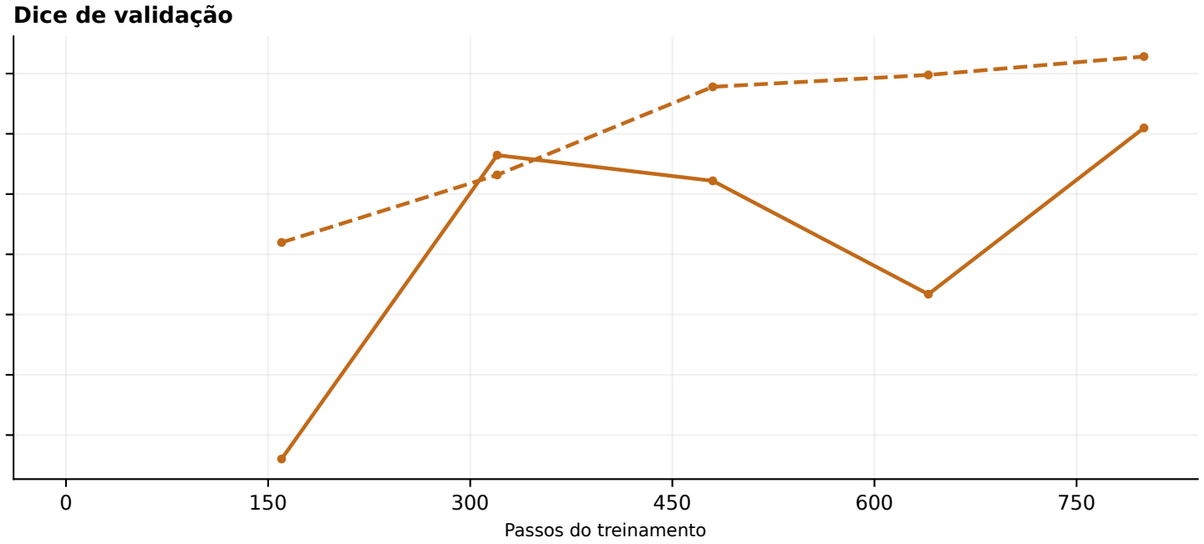
Learning rate principal



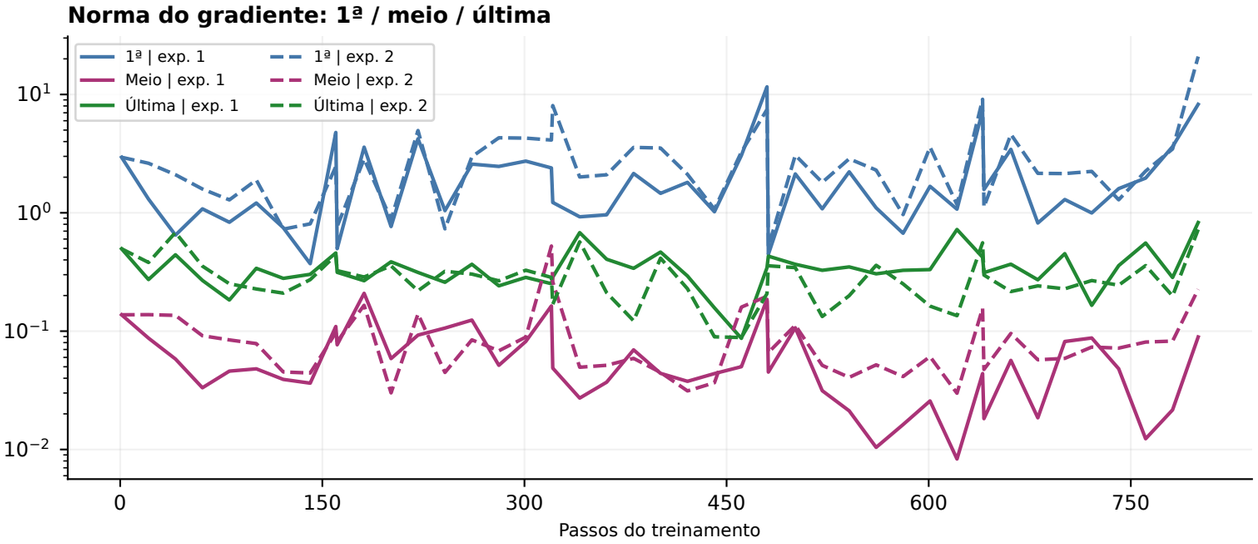
Razão de atualização: 1ª / meio / última



Dice de validação



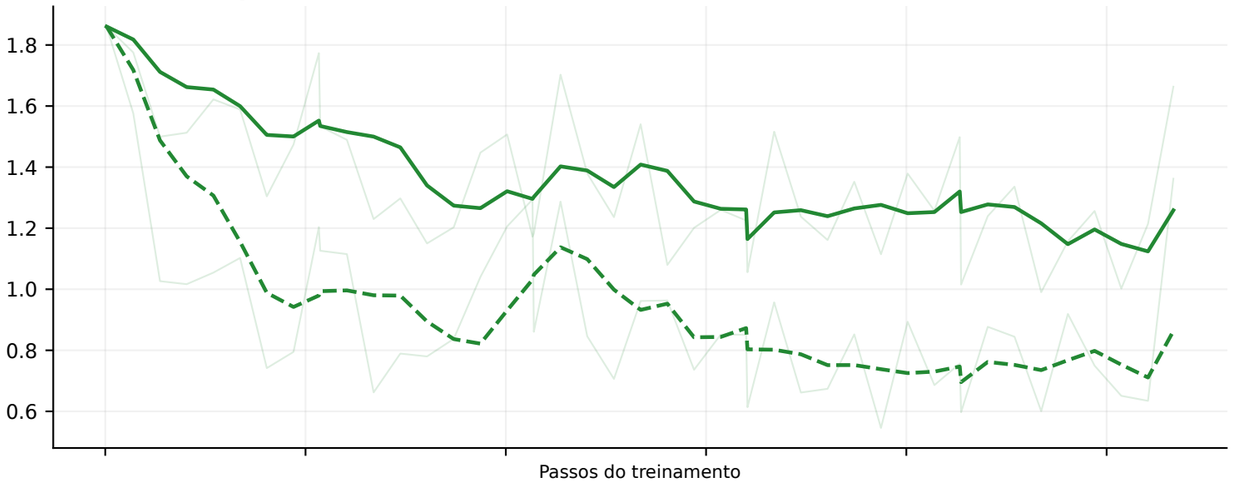
Norma do gradiente: 1ª / meio / última



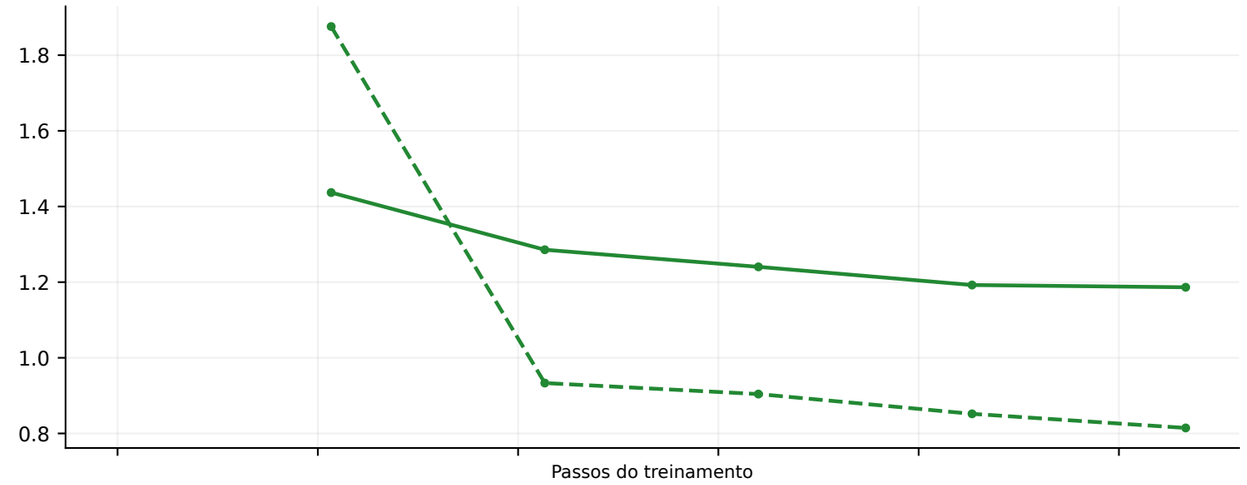
Muon | LR=0.003 | Constante | semente 42 | schedule_sweep
Muon | LR=0.003 | OneCycle | semente 42 | schedule_sweep

Controle de menor Dice (NÃO DIVERGENTE) | 5 épocas | substituto explícito por não haver divergência

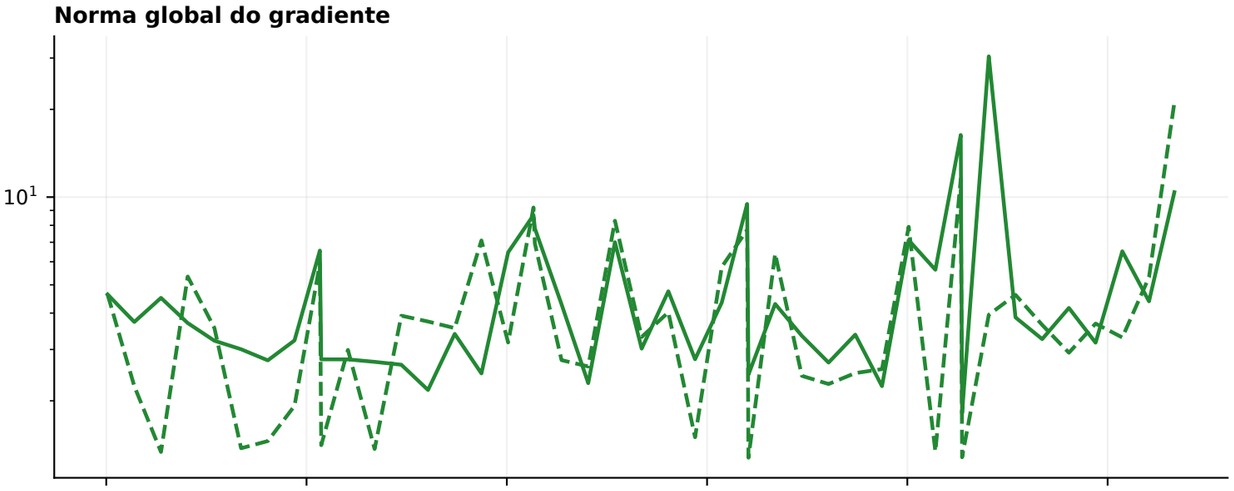
Loss de treino por lote



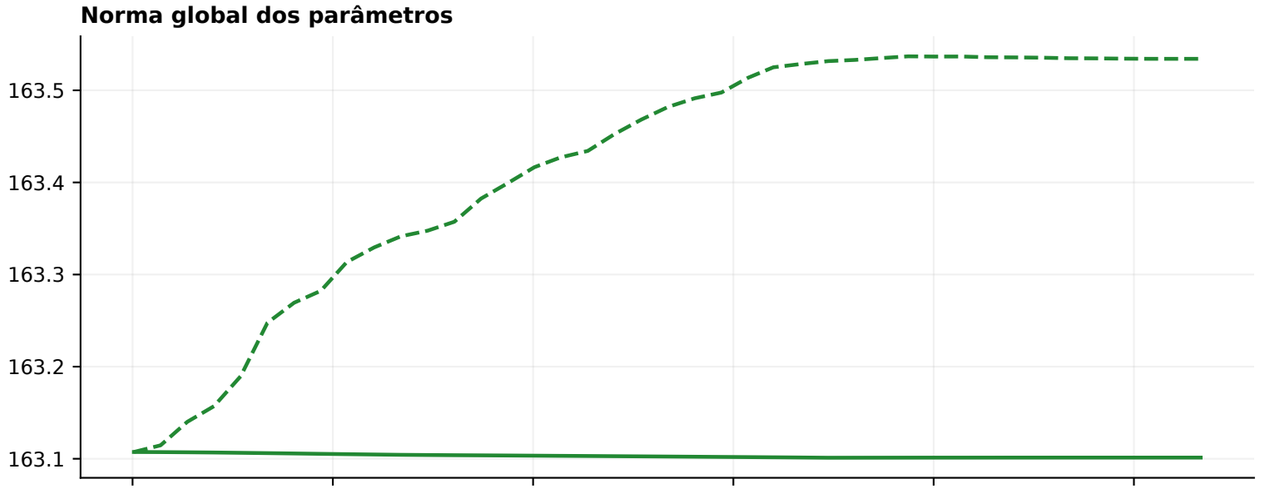
Loss de validação por época



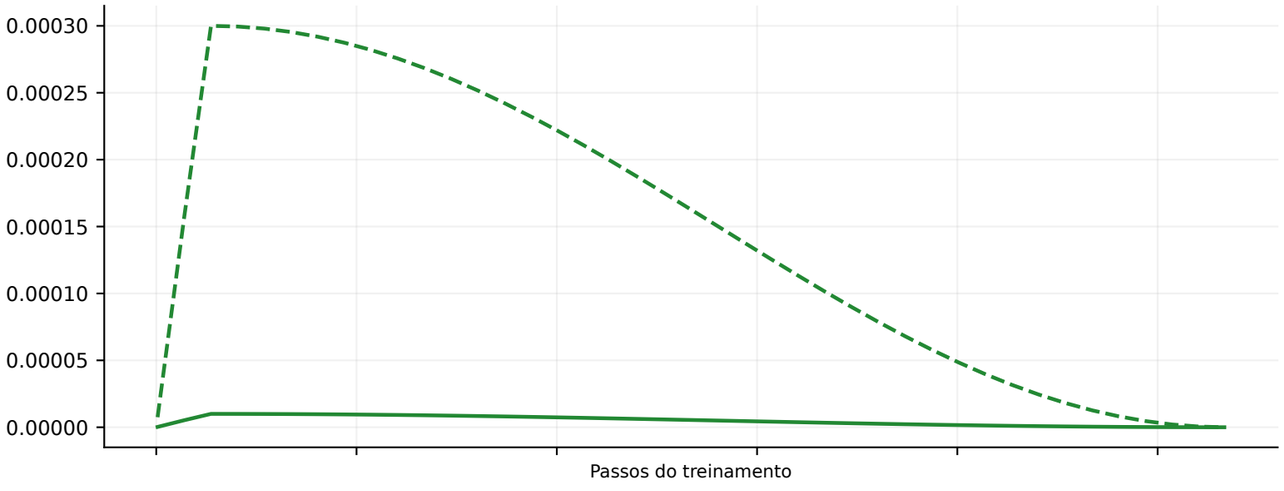
Norma global do gradiente



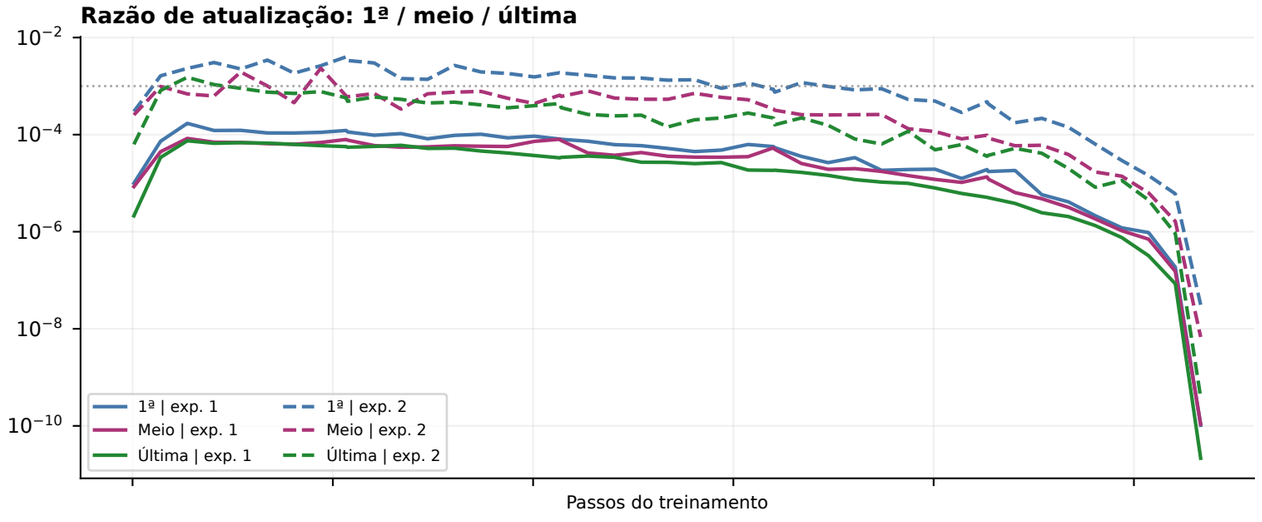
Norma global dos parâmetros



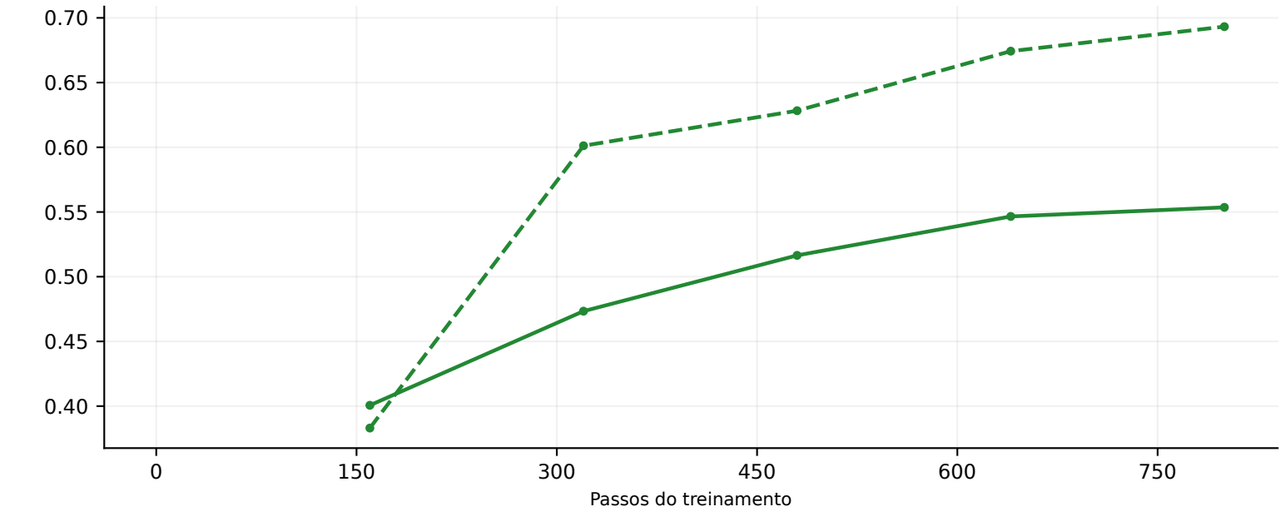
Learning rate principal



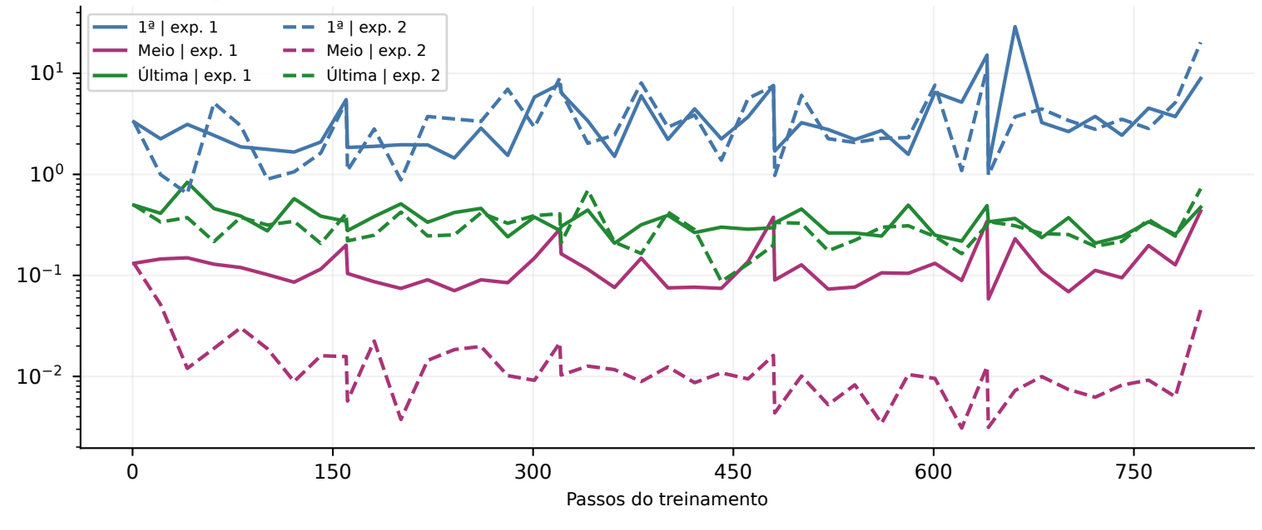
Razão de atualização: 1ª / meio / última



Dice de validação



Norma do gradiente: 1ª / meio / última



AdamW | LR=1e-05 | Warmup + cosseno | semente 42 | lr_sweep

AdamW | LR=0.0003 | Warmup + cosseno | semente 42 | lr_sweep

DIAGNÓSTICO DOS SINAIS — LEITURA DAS COMPARAÇÕES

1. VALIDAÇÃO: a receita Muon + OneCycle teve Dice médio 0.7510 ± 0.0017;
   baseline: 0.7267 ± 0.0058. Ganho pareado: +0.0243 Dice.
   Essa diferença é acompanhada por menor dispersão entre as três sementes.

2. BASELINE × VENCEDORA (página 4): compare as curvas de loss e Dice de validação.
   As taxas de aprendizado são diferentes; não interprete apenas o tamanho da
   atualização como prova isolada de que uma configuração é melhor.

3. MUON × ADAMW (página 5): sob o mesmo orçamento de cinco épocas,
   observe normas de gradiente e razões de atualização por camada.
   A linha horizontal em 10^-3 é uma referência orientativa, não uma meta.

4. CONSTANTE × ONECYCLE (página 6): OneCycle aumenta o LR inicialmente
   e reduz a taxa ao final; o controle constante não apresenta esse decaimento.
   Compare como isso acompanha as oscilações da loss e o Dice de validação.

5. CONTROLE DE BAIXO DICE (página 7): menor desempenho não é sinônimo
   de divergência. Nenhuma das 46 execuções foi marcada como divergente.

LIMITAÇÕES DO PROTOCOLO
Muon usou AdamW auxiliar com LR = 0,0001, enquanto a varredura de AdamW
identificou 0,0003 como melhor. Isso deve ser declarado, sem alterar os logs.
Os sinais são amostrados a cada 20 passos; resultados por época são pontos
discretos, não medições a cada passo. Apenas o conjunto de validação
foi usado para selecionar a configuração vencedora.